PRO-DEPLOY · STRATA_DEPLOY

Развёртывание сервера нейросети на движке Strata в облаке Intelion Cloud

Аренда сервера с видеокартами NVIDIA Tesla A10, установка движка Strata и моделей Qwen3.6-35B-A3B и Qwen3.8-Flash-Next, проверка программного интерфейса

Инструкция по развёртыванию и эксплуатации

Редакция 1.1 от 28.10.2026. Комплект развёртывания strata_deploy версии v1.0.0. Составлена по результатам фактического развёртывания на сервере Intelion Cloud с двумя Tesla A10.

Аннотация

Настоящая инструкция описывает полный порядок действий, необходимых для того, чтобы сотрудник, не имеющий специальной подготовки в администрировании серверов, самостоятельно арендовал в облаке Intelion Cloud сервер с графическими процессорами, установил на него движок Strata с одной из двух поддерживаемых моделей и получил работающий программный интерфейс, совместимый с OpenAI. Каждый шаг проверен на практике: сервер был создан, движок развёрнут, а интерфейс проверен запросами извне. Иллюстрации представляют собой снимки экрана, сделанные в ходе этого развёртывания, и протоколы работы терминала. Отдельный раздел объясняет, в каких случаях достаточно одной видеокарты, а в каких следует брать две, и как число видеокарт связано с количеством одновременно обрабатываемых запросов к нейросети.

Содержание

1. Назначение и область применения

2. Термины, определения и сокращения

3. Общие сведения о решении

4. Выбор конфигурации: одна или две видеокарты

5. Подготовка к работе

6. Создание сервера в Intelion Cloud

7. Подключение к серверу

8. Развёртывание Strata

9. Проверка работы программного интерфейса

10. Установка второй модели

11. Эксплуатация, остановка сервера и расходы

12. Типовые затруднения и способы их устранения

13. Требования безопасности

Приложение А. Сводка параметров развёртывания

1. Назначение и область применения

Инструкция предназначена для сотрудников, которым необходимо получить собственный сервер нейросети с программным интерфейсом, совместимым с OpenAI, без обращения к внешним платным сервисам языковых моделей. Документ охватывает весь жизненный цикл такого сервера: выбор конфигурации, оплату и создание виртуальной машины в облаке Intelion Cloud, подключение к ней, установку движка Strata и модели, проверку работы, повседневное управление, остановку и освобождение ресурсов.

Порядок действий одинаков для сотрудников, работающих на компьютерах под управлением Windows, macOS и Linux. Все действия на сервере выполняются либо в веб-терминале, открываемом прямо в браузере из личного кабинета Intelion, либо через стандартную программу `ssh`, которая входит в состав Windows 10 и Windows 11, macOS и Linux. Устанавливать на рабочий компьютер дополнительные программы и создавать ключи SSH не требуется.

Инструкция составлена для комплекта развёртывания **strata_deploy версии v1.0.0**. Номер версии является единственным, что нужно знать о комплекте: он указывается в команде скачивания (раздел 8.1), показывается сценарием при запуске и записывается на сервер, поэтому по нему всегда можно понять, что именно установлено (раздел 8.5). Если для работы выпущена более новая версия, в командах этой инструкции достаточно заменить `v1.0.0` на её номер; порядок действий при этом сохраняется, хотя отдельные сообщения программ могут отличаться от приведённых на рисунках.

2. Термины, определения и сокращения

Таблица 1. Термины и сокращения

Термин	Определение
API (Application Programming Interface)	Программный интерфейс приложения; в данной инструкции означает интерфейс сервера нейросети, к которому обращаются клиентские программы по протоколу HTTP по адресу вида `http://АДРЕС:18080/v1`.
GPU (Graphics Processing Unit)	Графический процессор, то есть видеокарта. Модель нейросети выполняется главным образом на видеокарте.
VRAM (Video Random Access Memory)	Память видеокарты. У Tesla A10 её объём составляет 24 ГБ, из которых программам доступно около 22,5 ГиБ.
RAM (Random Access Memory)	Оперативная память сервера. Движок Strata хранит в ней часть модели, не поместившуюся в память видеокарты.
vCPU (virtual Central Processing Unit)	Виртуальное ядро центрального процессора, выделяемое облаком виртуальной машине.
CUDA (Compute Unified Device Architecture)	Программная платформа NVIDIA для вычислений на видеокартах. CUDA Toolkit содержит компилятор, необходимый для сборки движка.
SSH (Secure Shell)	Защищённый протокол удалённого доступа к командной строке сервера.
VNC (Virtual Network Computing)	Протокол удалённого доступа к экрану компьютера. Веб-терминал Intelion является консолью VNC, открываемой в браузере.
Strata	Движок для запуска языковых моделей на основе llama.cpp, который предоставляет API, совместимый с OpenAI, умеет распределять запросы между несколькими копиями модели и держать часть модели в оперативной памяти.
Реплика	Отдельная копия модели, запущенная на одной видеокарте. На сервере с двумя видеокартами работают две реплики, а единый API распределяет между ними запросы.
Токен	Единица текста, которой оперирует модель; в среднем одно русское слово занимает два-три токена.
Контекст	Наибольший объём текста в токенах (запрос, история диалога и ответ), который модель учитывает одновременно.
Ключ API	Секретная строка вида `sk-strata-…`, без которой сервер отклоняет запросы. Передаётся в заголовке `Authorization: Bearer КЛЮЧ`.

systemd	Подсистема Linux, управляющая службами. Сервер нейросети работает как служба `strata` с автоматическим запуском при включении машины.

3. Общие сведения о решении

Решение состоит из трёх частей. Первая часть, облачный сервер Intelion Cloud, предоставляет виртуальную машину с операционной системой Ubuntu 24.04, драйвером NVIDIA и установленным CUDA Toolkit. Вторая часть, комплект развёртывания `strata_deploy`, хранит в себе исходный код движка Strata и библиотеки llama.cpp, поэтому при установке они ниоткуда не скачиваются и не зависят от изменений в сторонних репозиториях. Из интернета загружаются только пакеты Python и файлы самой модели с Hugging Face. Третья часть, интерактивный сценарий `deploy.sh`, задаёт несколько вопросов, проверяет сервер, собирает движок под установленные видеокарты, скачивает и проверяет модель, создаёт службу `strata` и в завершение проверяет API.

Комплект поддерживает две модели, сведения о которых приведены в таблице 2. Обе модели относятся к классу смеси экспертов: из всего множества параметров при обработке каждого токена работает лишь небольшая часть, поэтому модель на десятки миллиардов параметров отвечает с приемлемой скоростью на видеокарте с 24 ГБ памяти, а не поместившиеся в видеокарту эксперты хранятся в оперативной памяти сервера.

Таблица 2. Поддерживаемые модели

Параметр	Qwen3.6-35B-A3B	Qwen3.8-Flash-Next
Номер в меню `deploy.sh`	1 (по умолчанию)	2
Всего параметров	35 млрд, из них около 3 млрд активных на токен	125 млрд
Вариант сжатия	UD-Q4_K_XL (Unsloth)	IQ3_XXS (GSQ-RCO, ISTA-DASLab)
Объём скачивания	около 23 ГБ	около 76 ГБ
Место на диске (с движком и CUDA)	около 55 ГиБ	около 180 ГиБ
Оперативная память на две реплики	около 64 ГиБ	около 96 ГиБ
Имя модели в API	`qwen3.6-35b-a3b`	`qwen3.8-flash-next`
Дополнительное имя	`qwen3.6-35b-a3b-ud-q4_k_xl`	`qwen3.8-flash-next-iq3_xxs`
Когда выбирать	Быстрые ответы, агенты, вызов инструментов, умеренная нагрузка	Более сложные задачи рассуждения, когда качество важнее скорости

Запрос, в котором указано другое имя модели, сервер отклоняет, поэтому в настройках клиентских программ в поле `model` следует указывать именно постоянное имя из таблицы 2. Обработка изображений в данном комплекте отключена.

> **Важно: сервер держит одну модель за раз.** На сервере одновременно работает только одна из двух моделей, а все видеокарты отданы её репликам. Выбор модели в сценарии `deploy.sh` не добавляет вторую модель к первой, а заменяет её: служба `strata` перезапускается с новой моделью, и прежнее имя модели перестаёт приниматься API. Скачанные файлы прежней модели и собранный движок остаются на диске, поэтому обратное переключение занимает несколько минут (раздел 10). Если обе модели нужны одновременно, следует арендовать два сервера.

4. Выбор конфигурации: одна или две видеокарты

4.1. Как Strata использует видеокарты

Комплект запускает на каждой видеокарте собственную полную копию модели, называемую репликой. Реплики не делят модель между собой: каждая из них самостоятельно отвечает на запросы, а единый API принимает все входящие запросы на одном порту и распределяет их между репликами. Каждая реплика обрабатывает одновременно до четырёх запросов (параметр `PARALLEL=4`). Следовательно, количество одновременно обслуживаемых запросов растёт прямо пропорционально числу видеокарт: сервер с одной видеокартой обслуживает до четырёх запросов одновременно, а сервер с двумя видеокартами до восьми. Запросы сверх этого числа не теряются, а ожидают в очереди, пока освободится место в одной из реплик.

При распределении учитывается и то, что реплика уже держит в памяти начало запроса. Если несколько агентов используют одинаковый длинный системный промпт, повторно его обрабатывать не нужно, и выгодно направлять такие запросы на ту же реплику. Однако при стандартной настройке все такие запросы скапливались на одной реплике, а вторая простаивала. Поэтому комплект устанавливает параметр `replica_load_tokens` равным 20000: реплика считается загруженной раньше, и запросы равномернее расходятся по видеокартам. Значение установлено замерами модели Flash-Next на трёх видеокартах A10.

4.2. Когда достаточно одной видеокарты

Одной видеокарты Tesla A10 достаточно, если сервер нужен одному-двум сотрудникам, для проверки и отладки интеграции, для разовой обработки документов либо для агента, который отправляет запросы последовательно, по одному. В этом случае подходит модель Qwen3.6-35B-A3B: ей хватает конфигурации `1x Tesla A10, 64 ГБ DDR4` и диска 128 ГБ. Скрипт сам определит количество видеокарт и запустит одну реплику. Одна видеокарта обходится примерно вдвое дешевле двух (около 39 ₽ в час против 86 ₽ в час на момент составления инструкции). Кроме того, конфигурации с одной A10 обычно есть в наличии, тогда как конфигурации с двумя бывают в дефиците.

Модель Qwen3.8-Flash-Next на одной видеокарте возможна только в конфигурации `1x Tesla A10, 64 ГБ DDR4` с диском 256 ГБ: одна реплика этой модели закрепляет за собой около 40 ГБ оперативной памяти, и ещё около 16 ГБ нужно системе, поэтому конфигурации с 32 ГБ недостаточно. Запас памяти в этом случае невелик, а скорость одного запроса ниже, чем у Qwen3.6-35B-A3B (таблица 5), поэтому для одной видеокарты рекомендуется Qwen3.6-35B-A3B.

4.3. Когда нужны две видеокарты

Две видеокарты следует выбирать, если к серверу одновременно обращаются несколько сотрудников или программ: например, работает команда, подключено несколько агентов, ведётся пакетная обработка документов в несколько потоков. Важно понимать, что вторая видеокарта не ускоряет ответ на отдельный запрос, поскольку каждый запрос целиком обрабатывается одной репликой. Вторая видеокарта удваивает пропускную способность, то есть число запросов, обрабатываемых одновременно, и уменьшает время ожидания в очереди при нагрузке. Кроме того, две видеокарты с конфигурацией на 128 ГБ оперативной памяти позволяют запустить модель Qwen3.8-Flash-Next в двух репликах.

Таблица 3. Рекомендуемые конфигурации Intelion Cloud

Сценарий	Конфигурация	Диск	Модель	Одновременных запросов
Проверка, один-два пользователя, последовательные запросы	1x Tesla A10, 64 ГБ DDR4, 18 vCPU	128 ГБ	Qwen3.6-35B-A3B	до 4
Команда, несколько агентов, параллельная обработка	2x Tesla A10, 128 ГБ DDR4, 38 vCPU	128 ГБ	Qwen3.6-35B-A3B	до 8
Сложные задачи, качество важнее скорости	2x Tesla A10, 128 ГБ DDR4, 38 vCPU	256 ГБ	Qwen3.8-Flash-Next	до 8
Обе модели поочерёдно на одном сервере (конфигурация, на которой выполнена проверка данной инструкции)	2x Tesla A10, 128 ГБ DDR4, 38 vCPU	256 ГБ	обе	до 8

4.4. Замеры и оценка быстродействия

Быстродействие модели Qwen3.6-35B-A3B было замерено на развёрнутом сервере с двумя Tesla A10. Клиент отправлял одновременно 1, 4, 8 и 16 запросов; каждый запрос требовал ответа длиной 300 токенов при отключённых рассуждениях. Результаты приведены в таблице 4. Скорость указана в токенах в секунду: одна тысяча токенов соответствует примерно 400-500 русским словам.

Таблица 4. Замер Qwen3.6-35B-A3B на 2x Tesla A10 (две реплики по 4 места)

Одновременных запросов	Общая скорость, токенов/с	Скорость одного запроса, токенов/с	Время до получения последнего ответа, с
1	54,2	54,2	5,5
4	133,8	40,4	9,0
8	214,9	29,1	11,2
16	225,2	22,3	21,3

Замер подтверждает описанную выше модель работы. Пока число одновременных запросов не превышает восьми мест (по четыре на каждой видеокарте), общая скорость растёт: при восьми запросах сервер выдаёт в 4 раза больше текста в секунду, чем при одном, а каждый отдельный запрос замедляется умеренно, с 54 до 29 токенов в секунду. При шестнадцати запросах общая скорость почти не растёт (225 против 215 токенов в секунду), а время ожидания удваивается: восемь запросов обрабатываются, а восемь ждут в очереди. Сервер с одной видеокартой имеет четыре места, поэтому его предел наступает уже на четырёх одновременных запросах, а общая скорость под нагрузкой составляет примерно половину от показанной в таблице 4.

Для практических расчётов это означает следующее. Короткий ответ чат-бота (100-300 токенов без рассуждений) приходит за 2-6 секунд. Сервер с двумя A10 под непрерывной нагрузкой выдаёт около 200 токенов в секунду, то есть порядка 700 тысяч токенов в час. Этого достаточно для команды из 10-20 сотрудников, работающих в чате с паузами между запросами, либо для 6-8 агентов, непрерывно отправляющих запросы. С включёнными рассуждениями (по умолчанию) модель перед ответом пишет рассуждение длиной от сотен до нескольких тысяч токенов, поэтому ответ на простой вопрос занимает 10-20 секунд вместо одной-двух (раздел 9).

Модель Qwen3.8-Flash-Next на этом сервере не устанавливалась, поэтому её показатели в таблице 5 являются оценкой. Оценка основана на замерах, опубликованных в документации Strata для того же варианта сжатия IQ3_XXS на видеокартах сходного класса (62 токена в секунду на RTX 5070 12 ГБ, 26-35 токенов в секунду на RTX 3060 12 ГБ, 78 токенов в секунду суммарно при четырёх запросах на двух RTX A4000 16 ГБ), и на замере Qwen3.6-35B-A3B на A10 из таблицы 4. Flash-Next в 3,5 раза больше по числу параметров, держит большую часть экспертов в оперативной памяти и поэтому отвечает медленнее.

Таблица 5. Сравнение моделей на 2x Tesla A10

Показатель	Qwen3.6-35B-A3B (замер)	Qwen3.8-Flash-Next (оценка)
Скорость одного запроса	54-70 токенов/с	30-45 токенов/с
Общая скорость при 8 одновременных запросах	215 токенов/с	100-160 токенов/с
Мест для одновременных запросов	8 (по 4 на видеокарту)	8 (по 4 на видеокарту)
Время первой установки	около 7 минут (замер)	20-40 минут
Время запуска службы	42 секунды (замер)	3-15 минут
Занято видеопамяти / оперативной памяти	43 из 45 ГиБ / 44 из 126 ГиБ (замер)	почти вся видеопамять / около 80-90 ГиБ
Качество ответов	Хорошее для повседневных задач, агентов и кода	Выше на сложных задачах рассуждения и анализа

4.5. Если двух Tesla A10 нет в наличии

Комплект не привязан к модели A10: несмотря на название каталога `strata-2xa10`, сценарий `deploy.sh` сам определяет число и тип видеокарт, а программа установки собирает движок под обнаруженную архитектуру. Поэтому при отсутствии двух A10 можно выбрать другую видеокарту NVIDIA. Варианты в таблице 6 расположены в порядке предпочтения. Цены указаны с НДС за час работы с диском 128 ГБ по данным конфигуратора на 28.10.2026; для диска 256 ГБ к цене добавляется 1,92 ₽ в час. Наличие меняется в течение дня, поэтому перед выбором следует посмотреть индикатор наличия (раздел 6.2).

Таблица 6. Замена конфигурации 2x Tesla A10

Конфигурация	Цена, ₽/ч	Когда подходит и чем отличается
2x RTX 3090, 128 ГБ DDR4, 38 vCPU	129,12	Первая замена. Та же архитектура, что у A10 (Ampere, sm_86), и те же 24 ГБ памяти на видеокарту, поэтому всё описанное в инструкции применимо без изменений: 8 мест для запросов, обе модели. Память RTX 3090 быстрее, поэтому ответы можно ожидать примерно на треть быстрее, чем на A10, но аренда дороже в 1,5 раза.
2x RTX A5000, 128 ГБ DDR4, 38 vCPU	103,52	Вторая замена. Также архитектура Ampere (sm_86) и 24 ГБ памяти; по скорости близка к A10 или немного быстрее. 8 мест, обе модели.
1x Tesla A10, 64 ГБ DDR4, 18 vCPU	42,67	Если параллельная нагрузка невелика (раздел 4.2). 4 места для запросов; рекомендуется Qwen3.6-35B-A3B. Обычно есть в наличии. При росте нагрузки можно позже арендовать второй такой сервер.
1x RTX 3090, 64 ГБ DDR4, 18 vCPU	65,29	То же, что одна A10, но быстрее и дороже.
3x Tesla A10, 300 ГБ DDR4, 58 vCPU	137,94	Если нужно больше параллельных запросов: 3 реплики, 12 мест. Подходит для обеих моделей; именно на такой конфигурации подбирался параметр распределения `replica_load_tokens`.
1x Tesla A100 80 ГБ, 150 ГБ DDR4, 18 vCPU	229,69	Дорогой вариант на одну видеокарту с 80 ГБ памяти: модель целиком помещается в видеопамять, что заметно ускоряет Flash-Next. Одна реплика, 4 места. Имеет смысл, только если других вариантов нет или важна скорость одного запроса.

Следующие варианты выбирать не рекомендуется. RTX 4090 48 ГБ сдаётся только помесячно (минимальная предоплата 74 973 ₽ за месяц), поэтому для разовой работы не подходит. H100 и H200 заказываются через отдельную страницу и стоят многократно дороже, чем требует данная задача. Конфигурации «Без видеокарты» и образы Windows Server для Strata непригодны.

> **Примечание.** Фактически проверена только конфигурация 2x Tesla A10. Для остальных вариантов таблицы 6 порядок действий тот же, а сценарий сам подстроится под число видеокарт; оценки скорости даны по характеристикам видеокарт и требуют подтверждения замером.

> **Примечание.** Скрипт всегда запускает по одной реплике на каждую обнаруженную видеокарту. Выбор между одной и двумя видеокартами делается только при создании сервера в конфигураторе; никаких дополнительных настроек в `deploy.sh` для этого не требуется.

5. Подготовка к работе

5.1. Учётная запись и баланс

Для работы необходима учётная запись в личном кабинете Intelion Cloud по адресу `https://intelion.cloud/user_panel/`. Вход выполняется через Яндекс ID, Т-Банк или по адресу электронной почты с одноразовым кодом (рисунок 1). При первом входе сайт показывает окно о файлах cookie; достаточно выбрать вариант «Только необходимые».

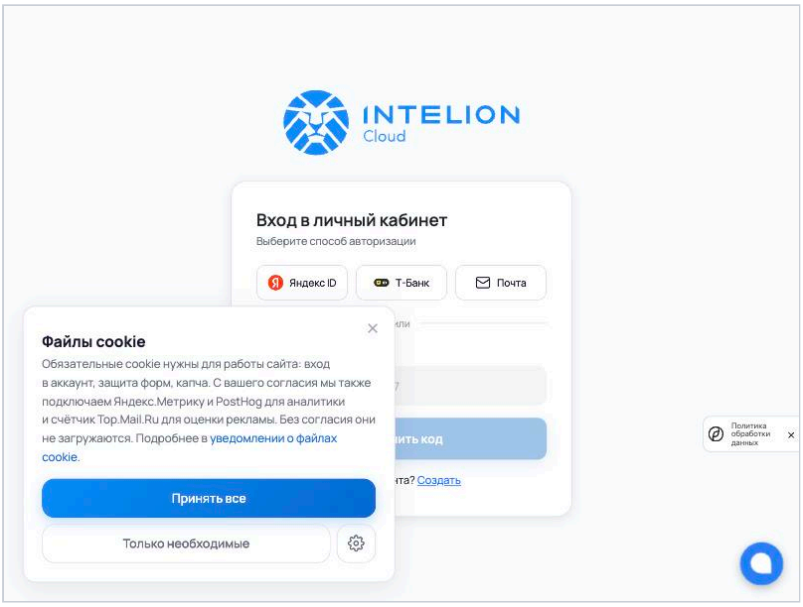


Рисунок 1. Страница входа в личный кабинет Intelion Cloud

В личном кабинете на вкладке «Серверы» отображается баланс (рисунок 2). Оплата аренды посекундная, однако при запуске сервер замораживает на балансе предоплату за выбранный период, минимум за один час. По окончании оплаченного часа при включённом автопродлении с баланса списывается следующий час. Если средств недостаточно, сервер останавливается, поэтому перед развёртыванием баланс следует пополнить с запасом не менее чем на два часа работы выбранной конфигурации: при проверке весь путь от запуска сервера до его остановки, включая развёртывание и замеры, занял 43 минуты и обошёлся в 60,86 ₽, но на непредвиденные задержки нужен запас.

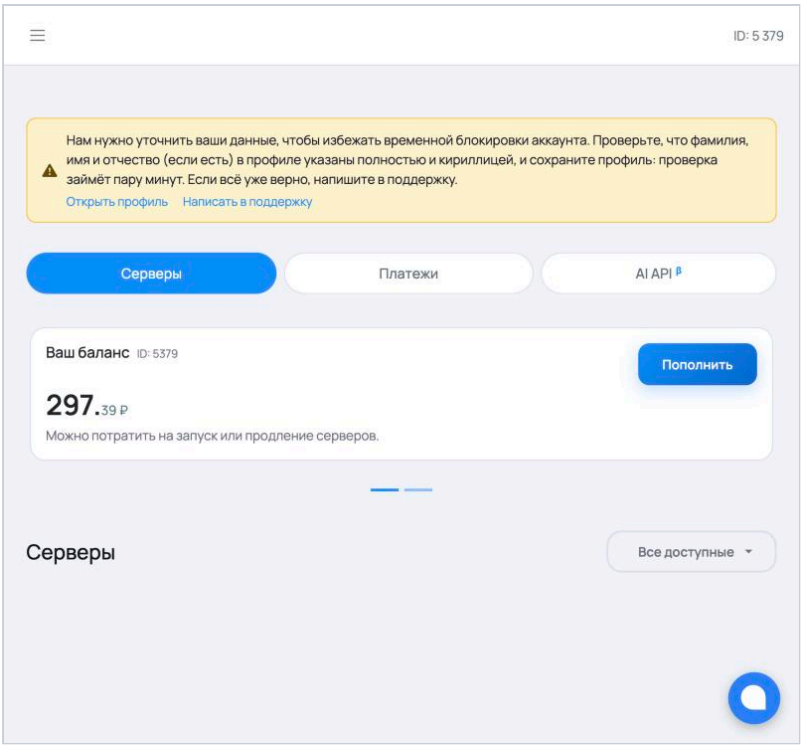


Рисунок 2. Личный кабинет: баланс и список серверов

Главное правило расходов: выключайте сервер, когда он не нужен. Оплата начисляется за всё время, пока сервер включён, независимо от того, обращается ли к нему кто-нибудь. Простаивающий сервер с двумя A10 стоит столько же, сколько работающий: 85,78 ₽ в час, то есть около 2 059 ₽ в сутки, около 14 400 ₽ в неделю и около 61 800 ₽ в месяц. Сервер, забытый включённым на выходные, расходует более 5 000 ₽. Поэтому по окончании работы сервер следует остановить (раздел 11.2), а при следующей необходимости запустить снова: Strata и модель сохраняются на диске, и после запуска служба поднимается сама примерно за минуту. Рекомендуется также включить уведомления о балансе и жизненном цикле серверов в Telegram или MAX (кнопка «Включить» в личном кабинете).

Внимание. Если в верхней части кабинета показано жёлтое уведомление с просьбой уточнить данные профиля, следует открыть профиль и указать фамилию, имя и отчество полностью и кириллицей. Иначе учётная запись может быть временно заблокирована, а вместе с ней станут недоступны и работающие серверы.

5.2. Что потребуется на рабочем компьютере

На рабочем компьютере нужен только современный браузер. Для работы через программу `ssh` (раздел 7.2), которая удобнее веб-терминала, потому что позволяет встав-

лять текст из буфера обмена, используется встроенная программа: в Windows 10 и Windows 11 это PowerShell или «Терминал Windows», в macOS это программа «Терминал». Создавать ключ SSH не требуется: вход выполняется по паролю, который Intelion создаёт автоматически.

6. Создание сервера в Intelion Cloud

6.1. Открытие конфигуратора

На вкладке «Серверы» нажмите «Создать сервер» (при пустом списке) или «+ Создать» (если серверы уже есть). Откроется конфигуратор GPU-сервера. В поле «Название» укажите понятное имя, например `strata-2xa10`; по умолчанию сайт подставляет случайное название. Тип сервера оставьте «С видеокартой», в разделе «Видеокарта (NVIDIA)» выберите «Tesla A10 - 24 Гб» (рисунок 3).

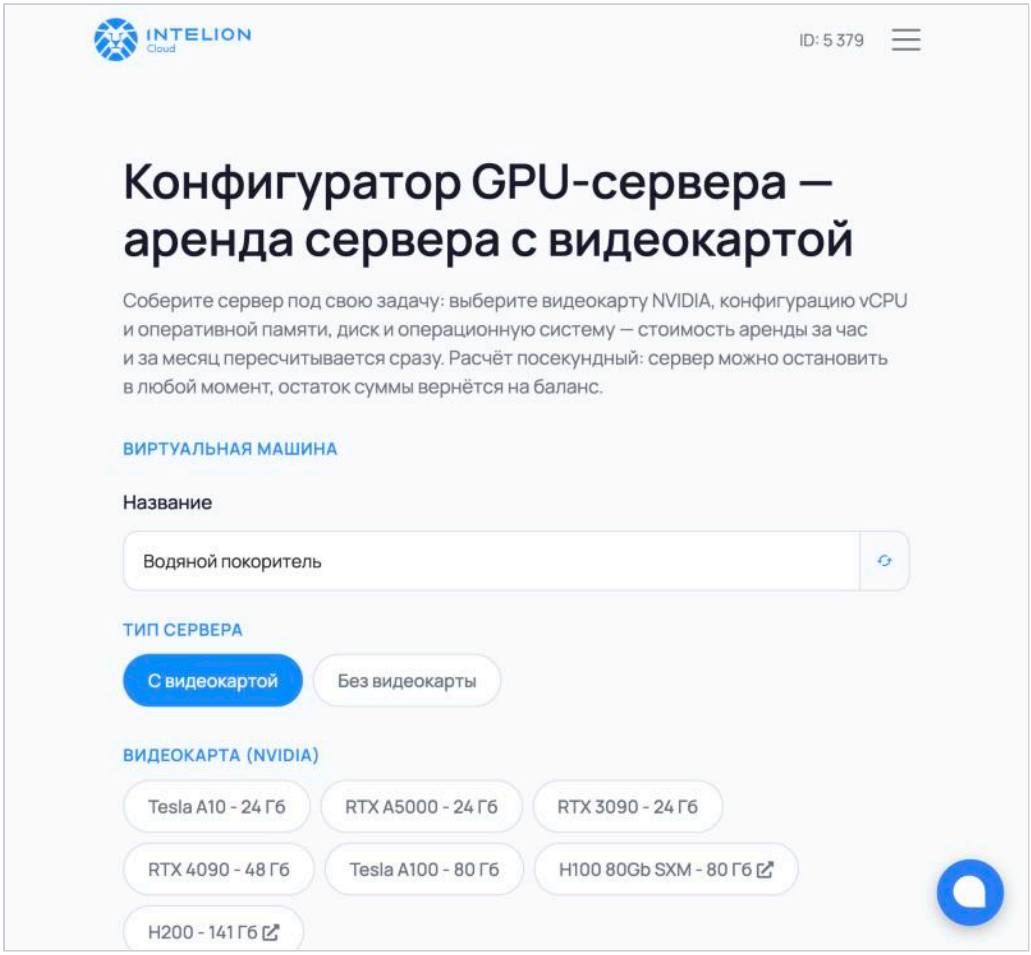


Рисунок 3. Конфигуратор: поле «Название» со случайным именем по умолчанию, тип сервера и модель видеокарты

6.2. Выбор конфигурации

В разделе «Конфигурация» выберите вариант в соответствии с таблицей 3. Для двух видеокарт это вариант «2x Tesla A10, 48 Гб VRAM, 128 Гб DDR4, 38 vCPU» (рисунок 4). Справа от каждого варианта расположен индикатор наличия свободных машин: три зелёных деления означают, что машин достаточно, одно красное деление означает, что машин мало, а серый индикатор означает, что вариант сейчас недоступен. При дефи-

ците вариант с двумя видеокартами может оказаться недоступен; в этом случае можно выбрать конфигурацию с одной видеокартой (раздел 4.2) или повторить попытку позднее.

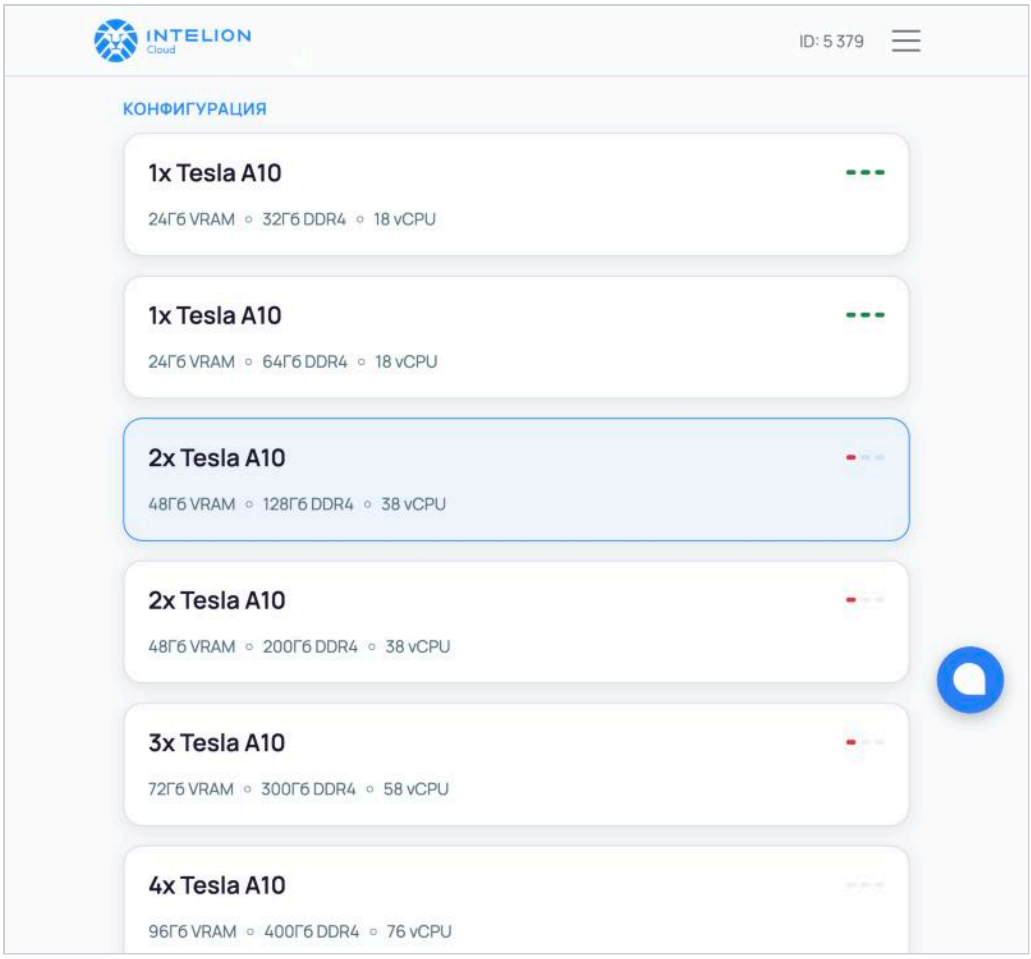


Рисунок 4. Выбор конфигурации «2x Tesla A10, 128 Гб DDR4» и индикаторы наличия

6.3. Операционная система и диск

В разделе «Операционная система» выберите **Ubuntu 24.04 с CUDA 13.3** (рисунок 5). Этот образ проверен: в нём уже установлены драйвер NVIDIA и CUDA Toolkit 13.3, поэтому программа установки не скачивает CUDA повторно и сразу переходит к сборке движка. Образ Ubuntu 22.04 также поддерживается. Образы Ubuntu 26.04 и Windows Server выбирать нельзя: программа установки Strata умеет автоматически ставить недостающие компоненты только на Ubuntu 22.04 и 24.04, а под Windows Server комплект не работает вовсе.

В разделе «Сетевой диск (NVMe)» задайте объём по таблице 3. Поле не принимает ввод с клавиатуры: размер меняется только кнопками «−» и «+», причём каждое нажатие «+» удваивает значение (128, 256 и так далее). Для модели Qwen3.8-Flash-Next либо для обеих моделей нажмите «+» один раз, чтобы получить 256 ГБ. Раздел «Дополнительное ПО» оставьте пустым.

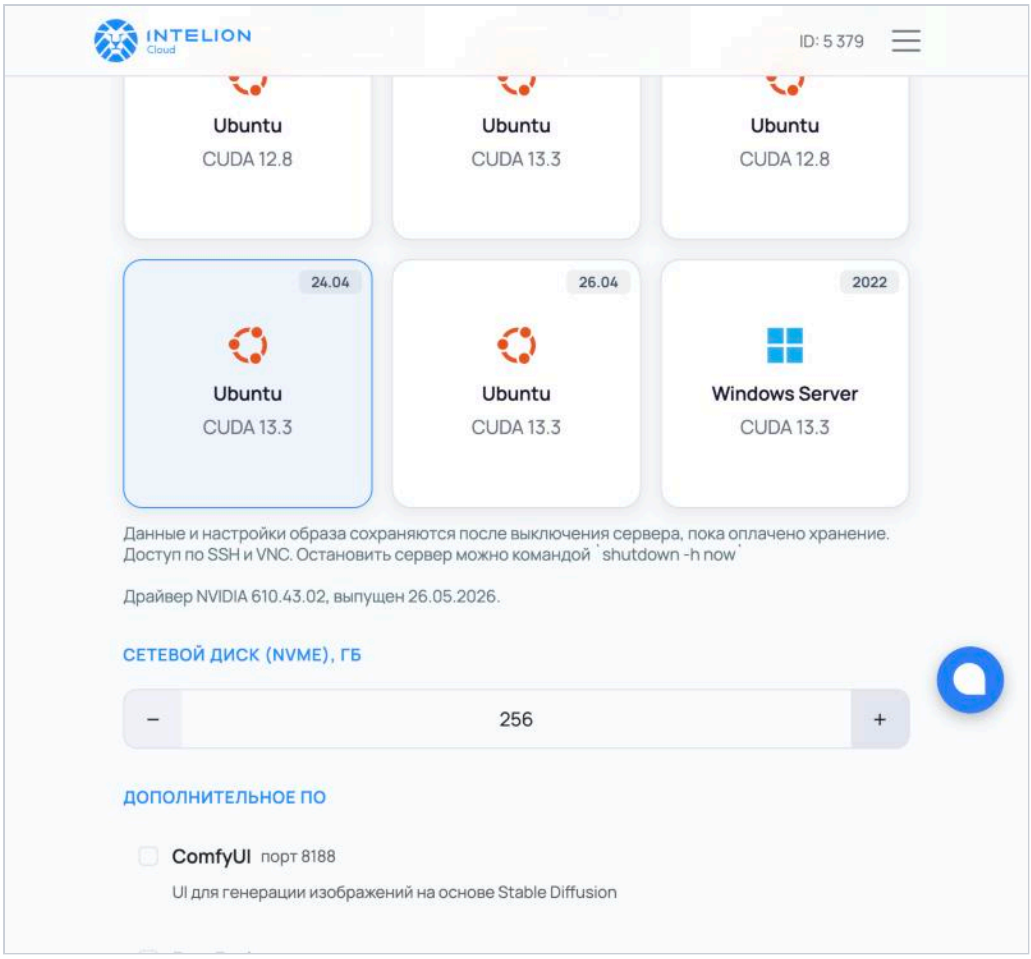


Рисунок 5. Выбор образа Ubuntu 24.04 с CUDA 13.3 и диска 256 ГБ

6.4. Ключ SSH и сумма предоплаты

Раздел «SSH-ключ (необязательно)» можно пропустить: пароль пользователя root создаётся автоматически в любом случае, и вся дальнейшая работа выполняется с этим паролем. Добавлять ключ имеет смысл только тем, кто уже пользуется ключами SSH (рисунки 6 и 7). Если ключ добавлен, он начинает приниматься сервером не сразу, а примерно через одну-две минуты после того, как статус сервера сменится на «Работает».

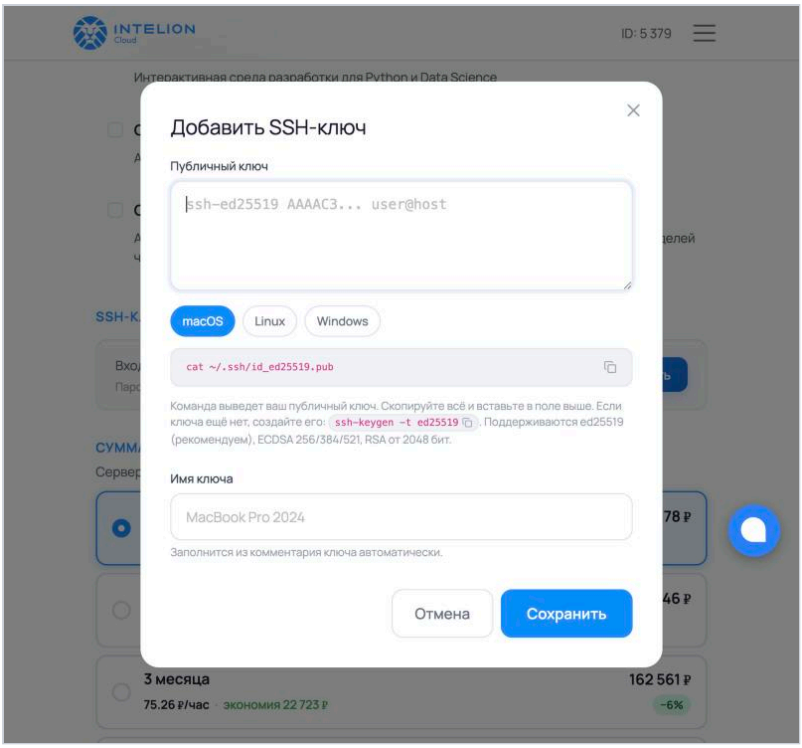


Рисунок 6. Необязательный шаг: окно добавления открытого ключа SSH

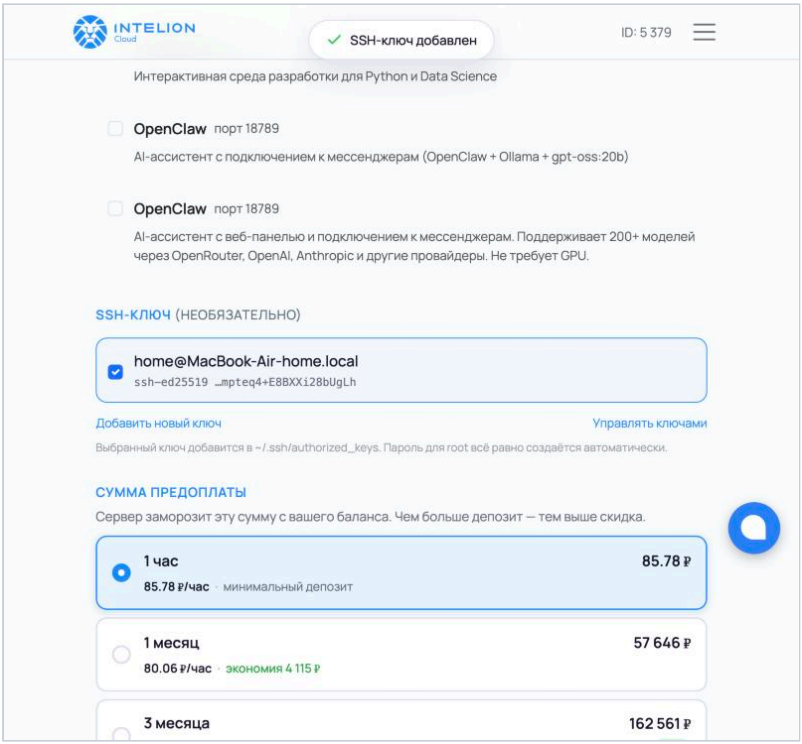


Рисунок 7. Ключ добавлен и отмечен для нового сервера

В разделе «Сумма предоплаты» оставьте вариант «1 час» (рисунок 8). Длительные периоды дают скидку от 7 до 20 процентов, но замораживают на балансе крупную сумму; их имеет смысл выбирать только для сервера, который будет работать постоянно. При досрочной остановке неизрасходованный остаток возвращается на баланс.

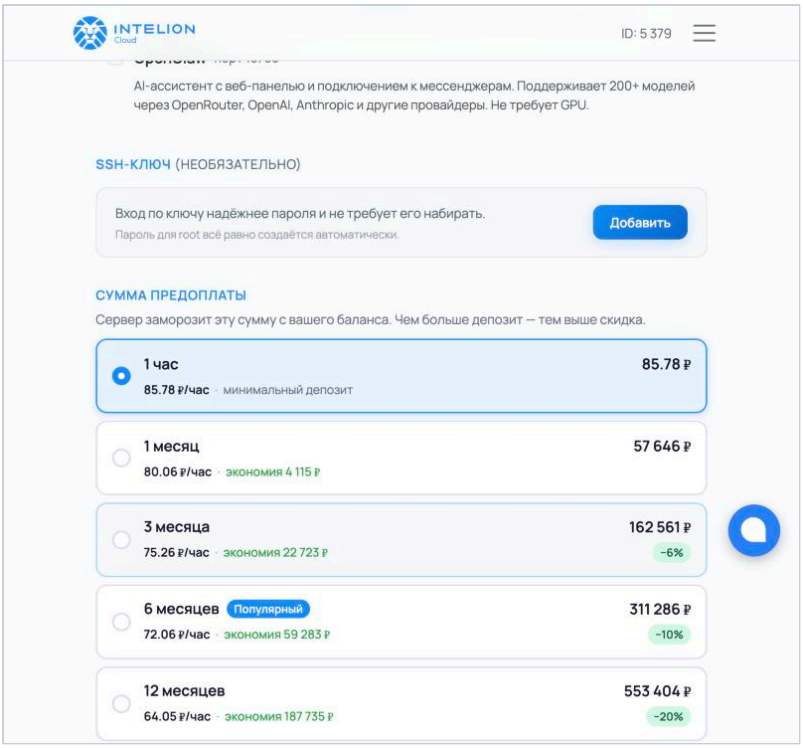


Рисунок 8. Сумма предоплаты: минимальный вариант на 1 час

6.5. Создание и запуск

Внизу страницы проверьте итоговую стоимость (рисунок 9). Для конфигурации из рисунков 4 и 5 она составила 85,78 ₽ в час с НДС: видеокарты 54,76 ₽, процессоры 8,49 ₽, оперативная память 15,26 ₽, диск 3,84 ₽ и инфраструктура 3,49 ₽. Нажмите «Создать».

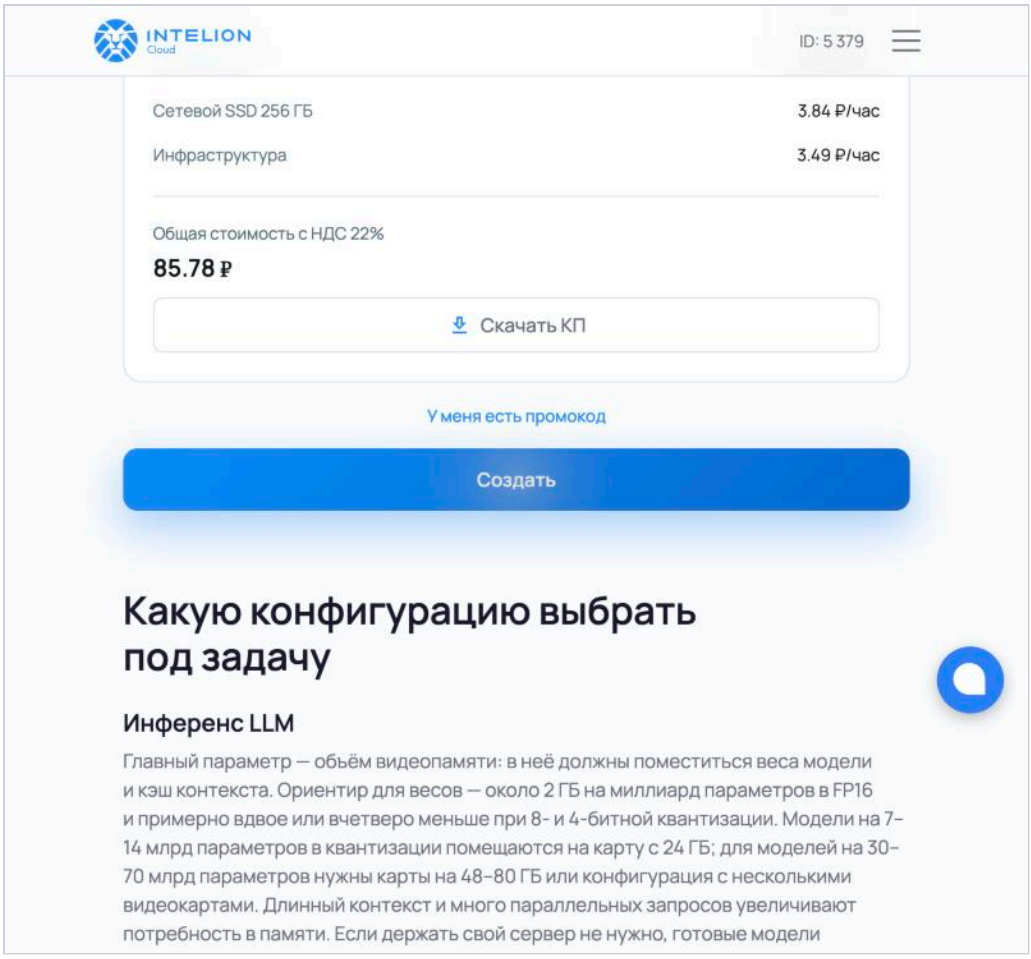


Рисунок 9. Итоговая стоимость и кнопка «Создать»

Сервер появится в списке со статусом «Ожидает запуска» (рисунок 10). Убедитесь, что переключатель «Автопродление» включён (по умолчанию он включён): без него сервер остановится через час, возможно, посреди установки. Нажмите «Запустить» и подтвердите списание в появившемся окне (рисунок 11).

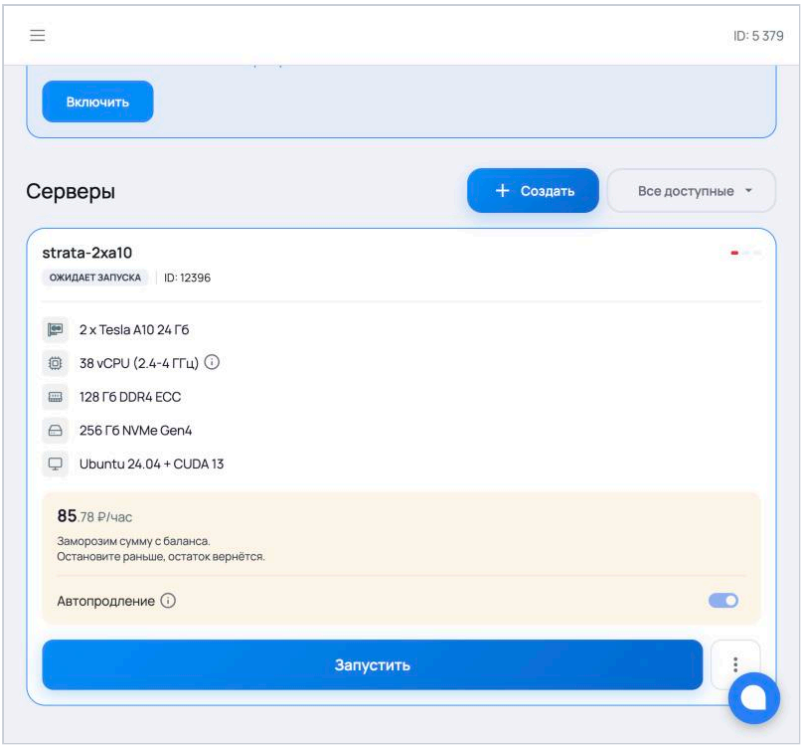


Рисунок 10. Созданный сервер в статусе «Ожидает запуска»

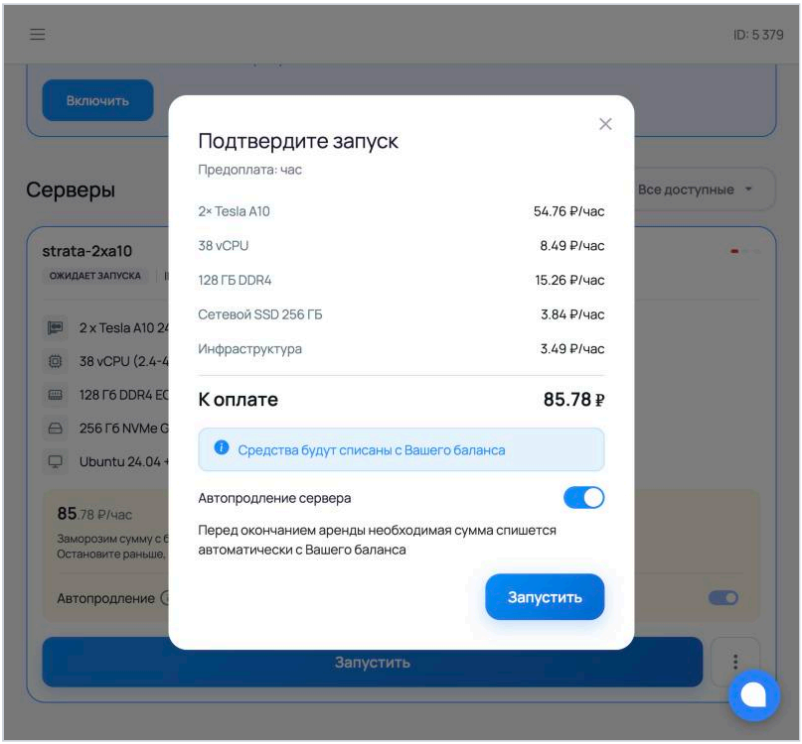


Рисунок 11. Подтверждение запуска и списания предоплаты

Статус сменится на «Запуск», а примерно через две-три минуты на «Работает»; при этом в карточке появится IP-адрес сервера (в рассматриваемом примере `185.182.108.28`). Обновить статус можно кнопкой «Проверить статус» или перезагрузкой страницы.

7. Подключение к серверу

Нажмите в карточке работающего сервера кнопку «Подключиться». Откроется окно «Подключение к серверу» (рисунок 12), в котором указаны готовая команда SSH, IP-адрес, логин `root` и скрытый пароль. Справа от каждого поля находится кнопка копирования. Пароль понадобится дважды: для входа на сервер и для ответа на вопрос сценария `deploy.sh`.

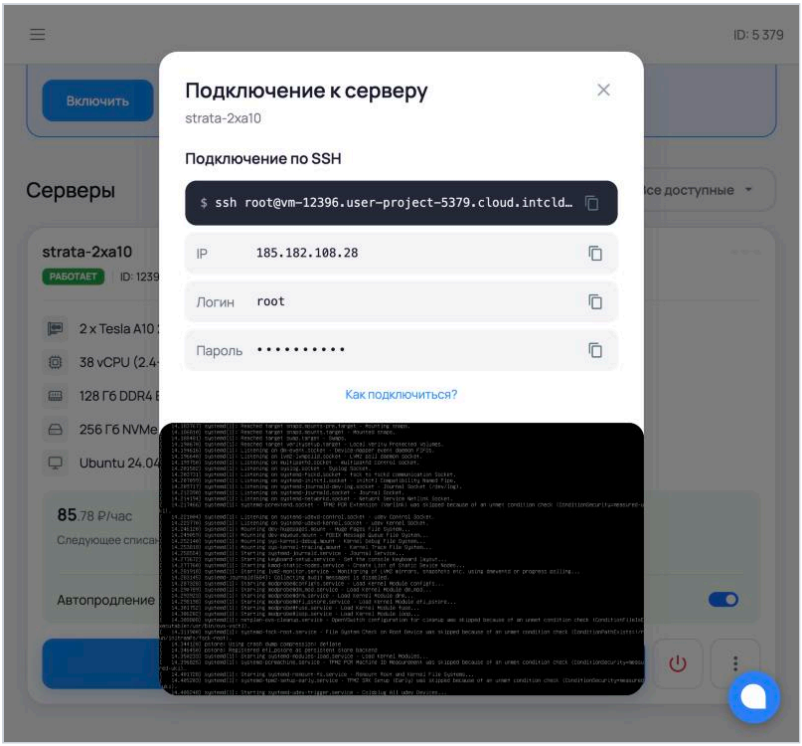


Рисунок 12. Окно «Подключение к серверу»: адрес, логин, пароль и веб-терминал

Подключиться можно одним из двух способов. Оба способа приводят к одному и тому же результату, а выбор определяется только удобством.

7.1. Способ А: веб-терминал в браузере

Нажмите «Открыть веб-терминал». В новой вкладке браузера откроется консоль сервера. На приглашение `login:` введите `root` и нажмите Enter, на приглашение `Password:` наберите пароль и нажмите Enter; при наборе пароль не отображается. После входа появится приветствие Intelion с данными о системе (рисунок 13), а внизу приглашение командной строки `root@vm…:~#`.

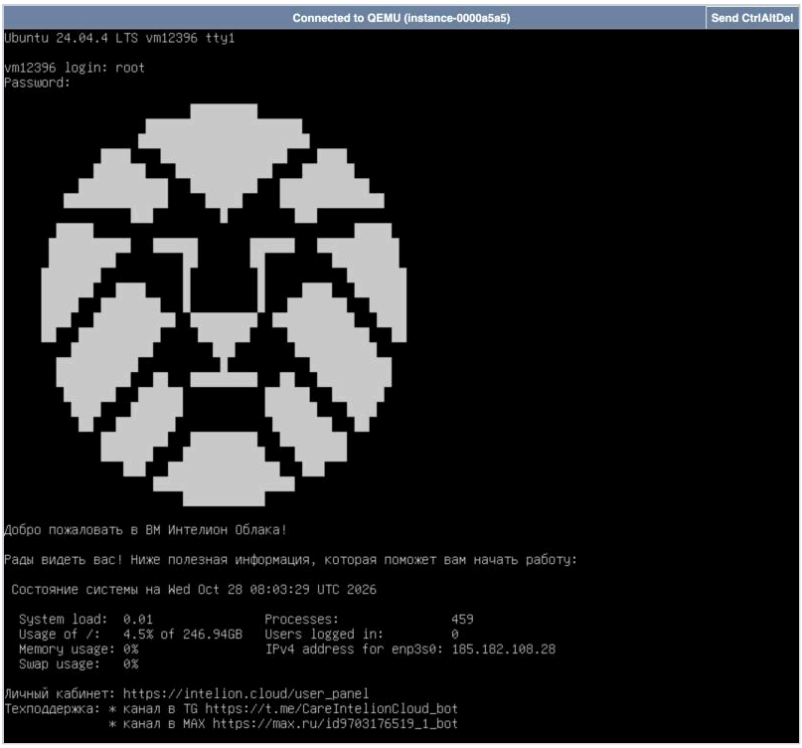


Рисунок 13. Веб-терминал после входа под пользователем root

> **Особенность веб-терминала.** Веб-терминал является консолью VNC и получает только нажатия клавиш. Вставка из буфера обмена в нём не работает, поэтому пароль и команды приходится набирать вручную, внимательно проверяя каждый символ. Раскладка клавиатуры в консоли всегда английская, кириллицу ввести нельзя: на вопросы «да/нет» отвечайте латинской буквой `y` (да) или `n` (нет) либо просто нажимайте Enter, принимая значение по умолчанию. Если окно консоли больше вкладки браузера, нижняя строка с приглашением может оказаться за краем экрана; в этом случае выполните команду `clear`, чтобы приглашение переместилось наверх.

7.2. Способ Б: программа ssh (рекомендуется)

В Windows откройте PowerShell (меню «Пуск», ввести «PowerShell») или «Терминал Windows», в macOS откройте программу «Терминал». Скопируйте из окна подключения команду SSH, вставьте её (в PowerShell вставка выполняется щелчком правой кнопки мыши, в macOS сочетанием Cmd+V) и нажмите Enter:

```
ssh root@185.182.108.28
```

При первом подключении программа спросит, доверять ли ключу сервера (`Are you sure you want to continue connecting`); ответьте `yes`. Затем вставьте пароль, скопированный кнопкой копирования из окна подключения, и нажмите Enter; символы пароля

при этом не отображаются. Этот способ удобнее веб-терминала, поскольку команды и пароль можно вставлять из буфера обмена и тем самым исключить опечатки.

> **Примечание.** На сервере работает защита fail2ban: после 15 неверных попыток ввода пароля в течение 10 минут адрес компьютера блокируется на один час. Если пароль не подходит, лучше скопировать его заново кнопкой копирования, чем подбирать.

8. Развёртывание Strata

8.1. Загрузка комплекта и запуск сценария

Все команды этого раздела выполняются на сервере, в веб-терминале или в окне ssh из раздела 7. Сначала загрузите комплект развёртывания с GitHub, затем запустите сценарий:

```
git clone --branch v1.0.0 https://github.com/pro-deploy/strata_deploy.git
bash strata_deploy/deploy.sh
```

Параметр `--branch v1.0.0` означает, что загружается именно выпущенная и проверенная версия комплекта, а не текущее рабочее состояние репозитория. Git при этом выводит предупреждение `You are in 'detached HEAD' state`; оно ожидаемо и на работу не влияет. Репозиторий занимает около 60 МБ и загружается за несколько секунд. Сценарий запускается непосредственно на сервере и подключается по SSH к нему же, указывая его собственный IP-адрес. Так проверка API в конце развёртывания выполняется через внешний адрес, то есть тем же путём, каким к серверу будут обращаться клиенты.

8.2. Ответы на вопросы сценария

Сценарий задаёт вопросы по порядку. Значение в квадратных скобках подставляется, если просто нажать Enter. Если ответ имеет неверный формат, вопрос повторяется с пояснением. Ответы приведены в таблице 7.

Таблица 7. Ответы на вопросы сценария deploy.sh

Вопрос	Ответ
Адрес сервера (IPv4 или доменное имя)	IP-адрес сервера из карточки, например `185.182.108.28`
Порт SSH [22]	Enter
Пользователь [root]	Enter
Пароль для root@…	Пароль root из окна подключения (рисунок 12). При вводе символы не отображаются. Пароль нигде не сохраняется.
Выберите нейросеть [1]	`1` для Qwen3.6-35B-A3B либо `2` для Qwen3.8-Flash-Next
Порт API [18080]	Enter
Начать развёртывание? (да/нет) [да]	Enter (в веб-терминале допускается также `y`)

После ввода пароля сценарий проверяет сервер и выводит его характеристики, а после выбора модели показывает профиль запуска и сводку параметров (рисунок 14). Сводку следует прочитать и убедиться, что указаны верный адрес, нужная модель и обе видеокарты.

```
root@vm12396:~# git clone https://github.com/pro-deploy/strata_deploy.git
Cloning into 'strata_deploy'...
Receiving objects: 100% (8050/8050), 58.47 MiB | 22.37 MiB/s, done.
root@vm12396:~# bash strata_deploy/deploy.sh
Развёртывание сервера нейросети на движке Strata
Значение в квадратных скобках подставляется, если просто нажать Enter.

1. Сервер
  Адрес сервера (IPv4 или доменное имя): 185.182.108.28
  Порт SSH [22]: Enter
  Пользователь [root]: Enter
  Подключение к root@185.182.108.28, порт 22...
  Пароль для root@185.182.108.28: (пароль не отображается)
  готово: вход выполнен, отпечаток ключа сервера сохранён в ~/.ssh/known_hosts.

2. Проверка сервера
  ОС: Ubuntu 24.04.4 LTS, архитектура x86_64, процессор 38 потоков, оперативная память
125 ГиБ
  Видеокарты (2 шт., драйвер 610.57.04):
      0) NVIDIA A10, 23028 МиБ
      1) NVIDIA A10, 23028 МиБ
  Свободно на диске /opt: 235 ГиБ
  Предыдущих развёртываний Strata этим скриптом не найдено.

3. Нейросеть
    1) Qwen3.6-35B-A3B (UD-Q4_K_XL): 35 млрд параметров (3 млрд активных), скачивание 23
ГБ, ...
    2) Qwen3.8-Flash-Next (IQ3_XXS): 125 млрд параметров, скачивание 76 ГБ, ...
  Выберите нейросеть [1]: 1
  Профиль: по одной копии модели на каждую из 2 видеокарт (0,1), до 4 одновременных
запросов на каждую.

4. Порт API
  Порт API [18080]: Enter

5. Проверьте параметры
  Сервер:            root@185.182.108.28, порт SSH 22
  Движок:            Strata из этого репозитория (снимок Niko1221/Strata@cbfd5b926b79),
...
  Комплект:          strata_deploy 482b6179d816
  Модель:            Qwen3.6-35B-A3B UD-Q4_K_XL, скачивание около 23 ГБ
  Имя в API:         qwen3.6-35b-a3b (также принимается qwen3.6-35b-a3b-ud-q4_k_xl)
  Видеокарты:        0,1, по одной копии модели на каждой, до 4 запросов на копию
  Каталоги:          /opt/strata (программа), /opt/strata-data (модели)
  Служба systemd:    strata.service
  API:               http://185.182.108.28:18080/v1
  Начать развёртывание? (да/нет) [да]: Enter
```

Рисунок 14. Вопросы сценария, результат проверки сервера и сводка параметров

Протокол записан до присвоения комплекту номера версии. В версии v1.0.0 первая строка сценария дополнена словами «(комплект strata_deploy v1.0.0)», а строка «Комплект» сводки имеет вид «strata_deploy v1.0.0 (коммит …)»; остальной вывод совпадает.

Если на сервере обнаружится нехватка оперативной памяти или места на диске относительно таблицы 2, либо работающие службы других нейросетей, сценарий предупредит об этом и задаст дополнительный вопрос. На новом сервере такие вопросы не появляются.

8.3. Ход установки

После подтверждения сценарий загружает комплект в каталог `/root/strata-kit` и запускает установку в фоне. Обрыв соединения или закрытие вкладки браузера установку не прерывает. Установка проходит этапы, приведённые в таблице 8; длительность каждого этапа замерена при данном развёртывании.

Таблица 8. Этапы установки и их фактическая длительность

№	Этап (сообщение в журнале)	Что происходит	Длительность
1-2	`Step 1: checking your PC`, `Step 2: your choices`	Проверка видеокарт, памяти и процессора; выбор варианта модели и длины контекста (для A10 автоматически выбран контекст 64K токенов).	несколько секунд
3	`Step 3: Python packages`	Создание окружения Python в `/opt/strata/.venv` и установка пакетов из PyPI.	около 1 минуты
4	`Step 4: the Strata engine`	Готового движка для этой версии нет (сообщение `no ready-made engine ... HTTP Error 404` ожидаемо), поэтому движок компилируется под видеокарты сервера компилятором CUDA 13.3 из образа. Компилятор выводит много предупреждений `warning #128-D`; они не являются ошибками.	около 2 минут
5	`Step 5: downloading ...`	Скачивание модели с Hugging Face и проверка контрольной суммы SHA-256 каждого файла.	около 3 минут (скачивание около 200 МБ/с)
6-7	`Step 6: preparing the model`, `Step 7: writing the start script`	Подготовка токенизатора, расчёт памяти под четыре одновременных запроса (около 3 ГБ видеопамяти на запрос), запись сценария запуска.	несколько секунд (для Flash-Next дольше)
8	`Waiting for the model to load`	Создание и запуск службы `strata`, загрузка модели в обе видеокарты; сценарий показывает индикатор загрузки.	42 секунды
	Итого	От подтверждения сводки до работающего API.	**около 7 минут**

```
6. Установка
  готово: комплект и исходный код Strata загружены в /root/strata-kit.
  Установка запущена на сервере. ... Ctrl+C прерывает только показ, установка
продолжится.
  Журнал на сервере: /root/strata-kit/install.log

=== Step 1: checking your PC ===
    GPU 0: NVIDIA A10, 22 GB VRAM - can be used
    GPU 1: NVIDIA A10, 22 GB VRAM - can be used
  [ok] GPU: NVIDIA A10, 22.5 GB VRAM, compute capability 8.6, driver 610.57.04
  [ok] RAM: 126 GB
  [ok] CPU: Intel(R) Xeon(R) Gold 6240R CPU @ 2.40GHz (AVX2)

=== Step 2: your choices ===
  [ok] model: Qwen3.6-35B-A3B
  [ok] size: UD-Q4_K_XL
  3) 64K tokens   (recommended for your GPU)
  [ok] context: 65536 tokens
  [ok] images: off

=== Step 3: Python packages ===
  [ok] numpy, jinja2, regex, pyyaml, tqdm, requests, cmake, ninja, pillow, psutil
installed

=== Step 4: the Strata engine ===
  [ok] llama.cpp 3cf0325 (gguf-py, ggml, mtmd)
  [!]  no ready-made engine at
https://github.com/Niko1221/Strata/releases/latest/download/ (HTTP Error 404: Not Found):
compiling instead
  [ok] build tools present (CUDA 13.3)
  ...
/opt/strata/src/kernels/cuda/native_mmvq.cu(1257): warning #128-D: loop is not reachable
  ...
[163/163] Linking CXX executable strata
  [ok] engine compiled: /opt/strata/engine/strata

=== Step 5: downloading Qwen3.6-35B-A3B UD-Q4_K_XL ===
  Qwen3.6-35B-A3B-UD-Q4_K_XL.gguf:  12.94 / 22.85 GB (57%)
```

Рисунок 15. Журнал установки: проверка оборудования, выбор параметров и сборка движка

Пока движок загружает модель в оперативную память и видеокарты, порт API закрыт, а сценарий вместо журнала показывает индикатор загрузки: прошедшее время, заполнение памяти видеокарт и оперативной памяти и последнюю строку журнала службы. Обычно загрузка занимает от 3 до 15 минут. Если модель не ответит за 30 минут или служба остановится с ошибкой, сценарий покажет последние строки журнала и завершится с сообщением об ошибке (раздел 12).

8.4. Завершение и ключ API

В завершение сценарий обращается к API по внешнему адресу и проверяет две вещи: что модель отвечает на запрос с ключом (код HTTP 200) и что запрос без ключа отклоняется (код HTTP 401). Затем сценарий предлагает показать ключ API; достаточно нажать Enter (рисунок 16).

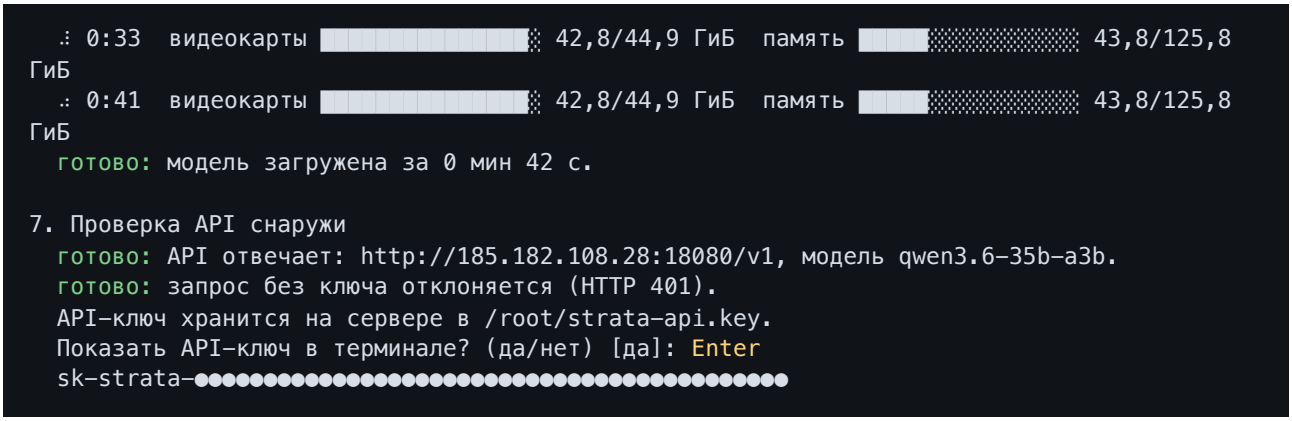


Рисунок 16. Завершение развёртывания: проверка API и ключ (ключ на рисунке скрыт)

Ключ хранится на сервере в файле `/root/strata-api.key`. Посмотреть его повторно можно командой `cat /root/strata-api.key`. Ключ следует передавать только тем сотрудникам, которым нужен доступ к серверу.

8.5. Как узнать и обновить версию

Версия комплекта, установленного на сервере, записана в файле `/opt/strata/deploy-info` в строке `version=`. Посмотреть её можно командой:

```
grep version /opt/strata/deploy-info
```

В ответ выводится строка вида `version=v1.0.0`. Если вместе с номером сценарий пишет пометку `-dirty` или слово `unknown` в строке коммита, значит комплект на компьютере, с которого выполнялось развёртывание, был изменён вручную или скачан без git; в этом случае рекомендуется скачать комплект заново командой из раздела 8.1.

Чтобы перейти на новую версию, например v1.1.0, на сервере выполняются три команды. Первая загружает сведения о новых версиях, вторая переключает комплект на нужную версию, третья повторно запускает сценарий, который использует уже скачанные модель и движок и меняет только то, что изменилось:

```
git -C strata_deploy fetch --tags
git -C strata_deploy checkout v1.1.0
bash strata_deploy/deploy.sh
```

Список выпущенных версий и описание изменений приведены на странице `github.com/pro-deploy/strata_deploy/releases`.

9. Проверка работы программного интерфейса

Адрес API имеет вид `http://АДРЕС:18080/v1`, ключ передаётся в заголовке `Authorization: Bearer КЛЮЧ`. Проверить работу можно с любого компьютера. В macOS и Linux используется команда `curl`:

```
curl -H "Authorization: Bearer КЛЮЧ" http://185.182.108.28:18080/v1/models
```

В Windows та же проверка выполняется в PowerShell:

```
Invoke-RestMethod -Uri http://185.182.108.28:18080/v1/models -Headers
@{Authorization = "Bearer КЛЮЧ"}
```

В ответ сервер возвращает список моделей (рисунок 17). Пробный запрос к модели выполняется так:

```
curl http://185.182.108.28:18080/v1/chat/completions \
  -H "Authorization: Bearer КЛЮЧ" -H "Content-Type: application/json" \
  -d '{"model":"qwen3.6-35b-a3b","messages":
[{"role":"user","content":"Привет! Ответь одним предложением."}]}'
```

```
$ curl -H "Authorization: Bearer КЛЮЧ" http://185.182.108.28:18080/v1/models
{"object": "list", "data": [
  {"id": "qwen3.6-35b-a3b", "object": "model", "status": {"value": "loaded"},
   "meta": {"n_ctx": 65536}, "aliases": ["qwen3.6-35b-a3b-ud-q4_k_xl"], ...},
  {"id": "qwen3.6-35b-a3b-ud-q4_k_xl", "alias_of": "qwen3.6-35b-a3b", ...}]}

$ curl http://185.182.108.28:18080/v1/models          (без ключа)
HTTP 401

$ curl .../v1/chat/completions ... "Привет! Ответь одним предложением: что ты умеешь?"
  "reasoning_content": "Here's a thinking process: 1. **Analyze User Input:** ..."  (3673
символа)
  "content": "Я умею отвечать на вопросы, решать задачи, писать тексты и код, переводить
              языки и помогать с самыми разными заданиями."
  usage: prompt 25, completion 933 токенов; 60,5 токена/с; время ответа 16,0 с

$ то же с "chat_template_kwargs": {"enable_thinking": false}
  "content": "Я большая языковая модель ... могу отвечать на вопросы, писать тексты,
              переводить языки, создавать код и многое другое."
  usage: prompt 27, completion 36 токенов; 70,0 токена/с; время ответа 1,0 с
```

Рисунок 17. Ответы API на запрос списка моделей и на пробный запрос

9.1. Рассуждения модели и параметр enable_thinking

Обе модели комплекта являются рассуждающими: прежде чем ответить, модель пишет рассуждение, которое API возвращает в отдельном поле `reasoning_content`, а сам ответ приходит в поле `content` (рисунок 17). Это важно учитывать при настройке клиен-

тов. Во-первых, рассуждение расходует токены из лимита `max_tokens`: при проверке с `max_tokens`, равным 400, модель израсходовала весь лимит на рассуждение, и поле `content` пришло пустым. Поэтому лимит следует либо не задавать, либо задавать с запасом (не менее 2000-4000 токенов). Во-вторых, рассуждение увеличивает время ответа: на простой вопрос модель рассуждала около 900 токенов и ответила за 16 секунд.

Для простых задач (классификация, извлечение данных, короткие ответы чат-бота) рассуждения целесообразно отключать. Для этого в тело запроса добавляется параметр `"chat_template_kwargs": {"enable_thinking": false}`; при отключённых рассуждениях тот же вопрос получил ответ за 1 секунду. В библиотеке `openai` для Python параметр передаётся через `extra_body`:

```
from openai import OpenAI

client = OpenAI(base_url="http://185.182.108.28:18080/v1", api_key="КЛЮЧ")
reply = client.chat.completions.create(
    model="qwen3.6-35b-a3b",
    messages=[{"role": "user", "content": "Кратко: что такое реплика
модели?"}],
    extra_body={"chat_template_kwargs": {"enable_thinking": False}},
)
print(reply.choices[0].message.content)
```

Для сложных задач (анализ документов, программирование, многошаговые рассуждения) рассуждения следует оставлять включёнными: они заметно повышают качество ответа.

9.2. Проверка одновременных запросов

Распределение нагрузки между видеокартами проверено отправкой 1, 4, 8 и 16 одновременных запросов (таблица 4 в разделе 4.4). Во время проверки обе видеокарты были загружены, а в журнале службы видно, как реплики отвечают параллельно (рисунок 18).

В клиентских программах, поддерживающих OpenAI (библиотеки `openai` для Python и JavaScript, LangChain, редакторы с поддержкой собственного сервера моделей), указываются три параметра: базовый адрес `http://АДРЕС:18080/v1`, ключ API и имя модели из таблицы 2.

10. Установка второй модели

Вторая модель, Qwen3.8-Flash-Next, устанавливается тем же сценарием `deploy.sh`. В ходе подготовки данной инструкции её установка не выполнялась, поэтому

длительности и показатели быстродействия в этом разделе являются оценкой (раздел 4.4, таблица 5), а порядок действий соответствует проверенному для первой модели.

> **Напоминание.** Сервер держит одну модель за раз. Установка Flash-Next заменяет работающую Qwen3.6-35B-A3B: на время установки и загрузки API недоступен, а после неё в поле `model` клиентских программ нужно указать `qwen3.8-flash-next`.

10.1. Чем отличается вторая модель

Qwen3.8-Flash-Next содержит 125 млрд параметров против 35 млрд у Qwen3.6-35B-A3B. Модель лучше справляется со сложными задачами рассуждения, анализа и программирования, но отвечает медленнее (таблица 5) и требует больше ресурсов. Её эксперты не помещаются в видеокарту и хранятся в оперативной памяти сервера: каждая реплика закрепляет за собой около 40 ГБ оперативной памяти, поэтому для двух реплик нужна конфигурация со 128 ГБ. Скачивание занимает около 76 ГБ, а программа установки дополнительно готовит из скачанных файлов пакет экспертов для движка, поэтому на диске требуется около 180 ГиБ свободного места, то есть диск 256 ГБ. Число мест для одновременных запросов такое же: по четыре на каждую видеокарту.

10.2. Порядок установки

1. Убедитесь, что сервер создан с диском 256 ГБ и оперативной памятью 128 ГБ (таблица 3). Если сервер создан с диском 128 ГБ, сценарий предупредит о нехватке места; в этом случае установку следует прервать ответом «нет», а сервер пересоздать с диском 256 ГБ.

2. Подключитесь к серверу (раздел 7) и выполните `bash strata_deploy/deploy.sh`. Повторно загружать комплект командой `git clone` не нужно.

3. Сценарий запоминает ответы предыдущего запуска (кроме пароля), поэтому на вопросы об адресе, порте SSH и пользователе достаточно нажать Enter. Введите пароль root.

4. На вопрос «Выберите нейросеть» ответьте `2`. Порт API и подтверждение сводки примите нажатием Enter. Сценарий покажет в сводке строку «Сейчас развёрнуто» с прежней моделью.

5. Дождитесь окончания установки. Окружение Python и собранный движок используются повторно, поэтому этапы 3 и 4 таблицы 8 проходят за секунды. Основное время занимают скачивание 76 ГБ (при скорости, наблюдавшейся на сервере Intelion, около 7 минут), проверка контрольных сумм, подготовка пакета экспертов

и загрузка модели в оперативную память и видеокарты (от 3 до 15 минут). Ориентировочная общая длительность составляет 20-40 минут.

6. Проверьте API (раздел 9), указав в запросах имя `qwen3.8-flash-next`.

10.3. Обратное переключение

Чтобы вернуться к Qwen3.6-35B-A3B, снова выполните `bash strata_deploy/deploy.sh` и на вопрос о нейросети ответьте `1`. Файлы модели уже лежат в `/opt/strata-data` и повторно не скачиваются, а сценарий лишь проверяет их, перезаписывает конфигурацию запуска и перезапускает службу, поэтому переключение занимает несколько минут. Ключ API при переключении не меняется.

11. Эксплуатация, остановка сервера и расходы

11.1. Управление службой

Сервер нейросети работает как служба `strata` и запускается автоматически при включении машины. Состояние, перезапуск и журнал службы доступны стандартными командами на сервере:

```
systemctl status strata
systemctl restart strata
journalctl -u strata -f
```

Вывод команды `systemctl status strata` на рабочем сервере показан на рисунке 18: служба активна и включена в автозапуск, в ней работают общий API (`server.py`) и два процесса движка, по одному на каждую видеокарту, а в журнале видно, как реплики параллельно отвечают на запросы.

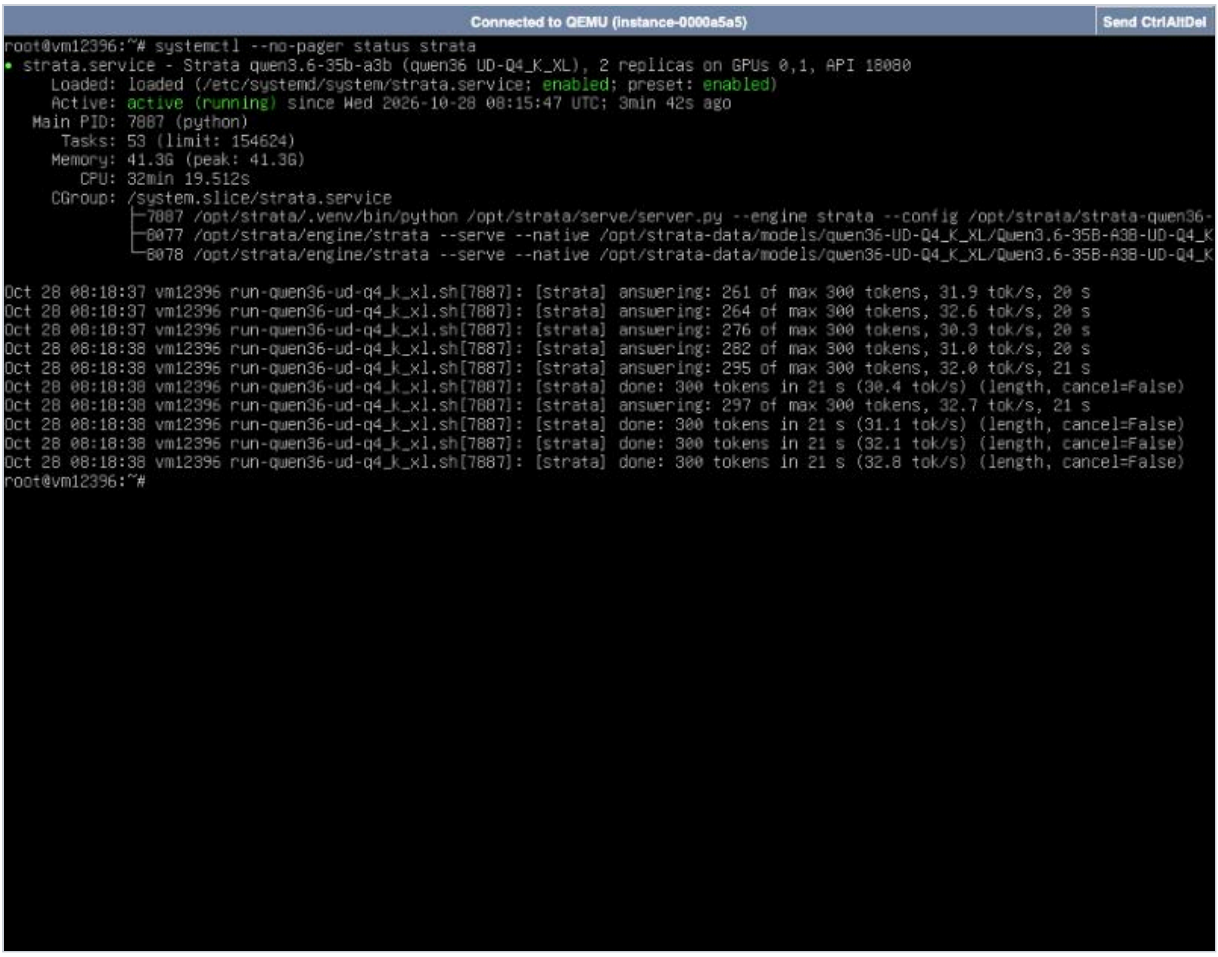


Рисунок 18. Состояние службы strata: две реплики на видеокартах 0 и 1

Журналы каждой реплики находятся в каталоге `/opt/strata` (файлы `strata-<модель>.r0.log`, `strata-<модель>.r1.log`). Загрузку видеокарт показывает команда `nvidia-smi` (рисунок 19): на каждой видеокарте работает процесс `/opt/strata/engine/strata`, занимающий около 21,9 ГиБ видеопамяти. Это нормальное состояние: движок заранее резервирует память под модель и под кэш контекста четырёх одновременных запросов.

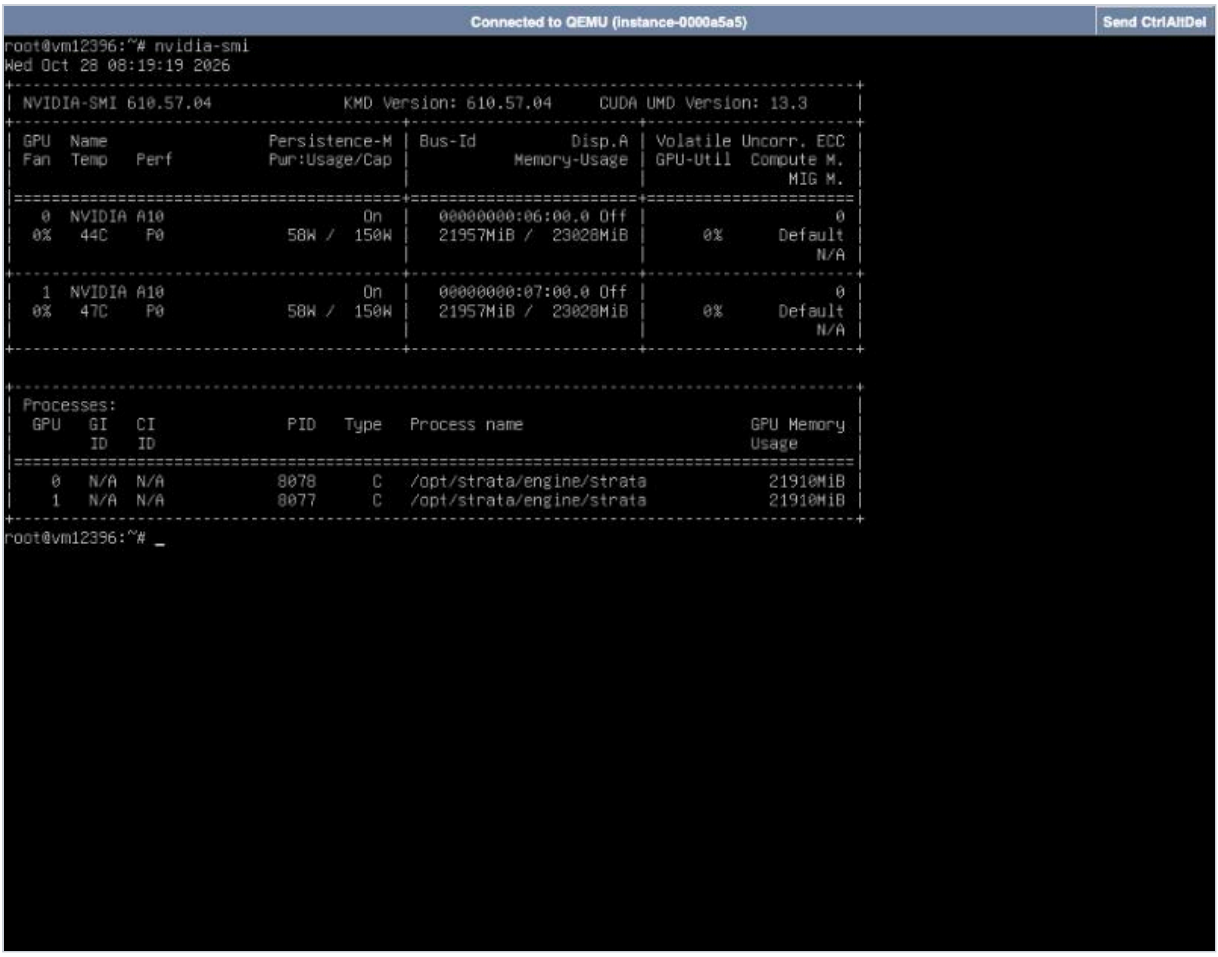


Рисунок 19. Обе видеокарты заняты репликами модели (вывод nvidia-smi)

Файл `/opt/strata/deploy-info` (рисунок 20) содержит время развёртывания, снимок Strata, коммит комплекта, модель и число реплик. По нему всегда можно установить, какой именно код и какая модель работают на сервере.



Рисунок 20. Содержимое файла /opt/strata/deploy-info

Обновления пакетов Ubuntu не перезапускают службу автоматически, чтобы не прерывать обработку запросов. После обновления системных библиотек службу нужно перезапустить вручную в удобное время.

11.2. Остановка сервера и расходы

Оплата посекундная, но предоплата списывается почасово, пока сервер работает и включено автопродление. Сервер, который не нужен, следует останавливать кнопкой выключения (значок питания) в карточке сервера. Панель запрашивает подтверждение (рисунок 21) и предупреждает о двух важных последствиях. Во-первых, оборудование освобождается: если его займут другие клиенты, запустить сервер снова получится, только когда появится свободное. При дефиците конфигураций с двумя A10 это может занять продолжительное время. Во-вторых, диск сохраняется вместе с установленными Strata и моделью: первые трое суток после остановки бесплатно, а затем за хранение списывается 5 ₽ за 1 ГБ в месяц, то есть для диска 256 ГБ около 1,78 ₽ в час или около 1280 ₽ в месяц.

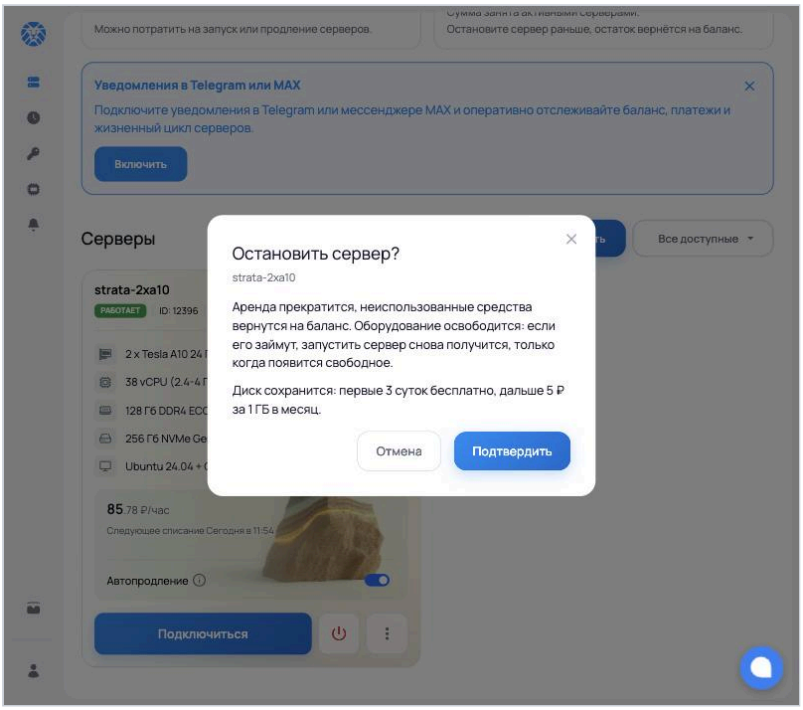


Рисунок 21. Подтверждение остановки сервера

После подтверждения статус сменяется на «Останавливается», а примерно через минуту на «Приостановлен», и панель показывает итог: продолжительность работы и списанную сумму (рисунок 22). Неизрасходованный остаток предоплаты сразу возвращается на баланс. При проверке сервер проработал 42 минуты 34 секунды, за это время были выполнены развёртывание Strata и все замеры, списано 60,86 ₽, а 24,92 ₽ из оплаченного часа вернулись на баланс.

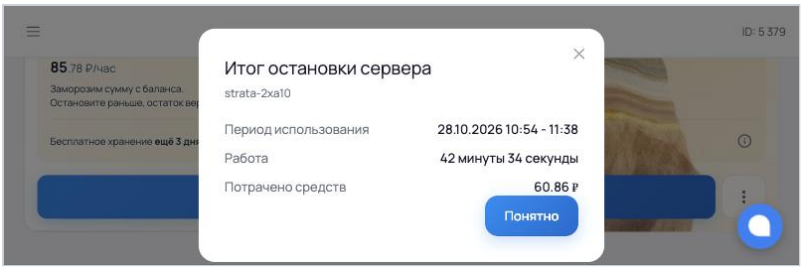


Рисунок 22. Итог остановки сервера: время работы и списанная сумма

11.3. Сохранение данных после выключения и стоимость хранения

Остановка не удаляет сервер. Пока сервер не удалён, его диск сохраняется целиком: операционная система, установленный движок Strata, скачанные модели в `/opt/strata-data`, ключ API, служба `strata` и все прочие файлы. В карточке приостановленного сервера отображается кнопка «Запустить» и срок бесплатного хранения (рисунок 23). После повторного запуска служба `strata` стартует автоматически, модель загружается примерно за минуту, и сервер снова отвечает по тому же ключу API. Устанавливать что-либо заново не нужно. IP-адрес после повторного запуска может измениться, поэтому его следует посмотреть в карточке и сообщить пользователям.

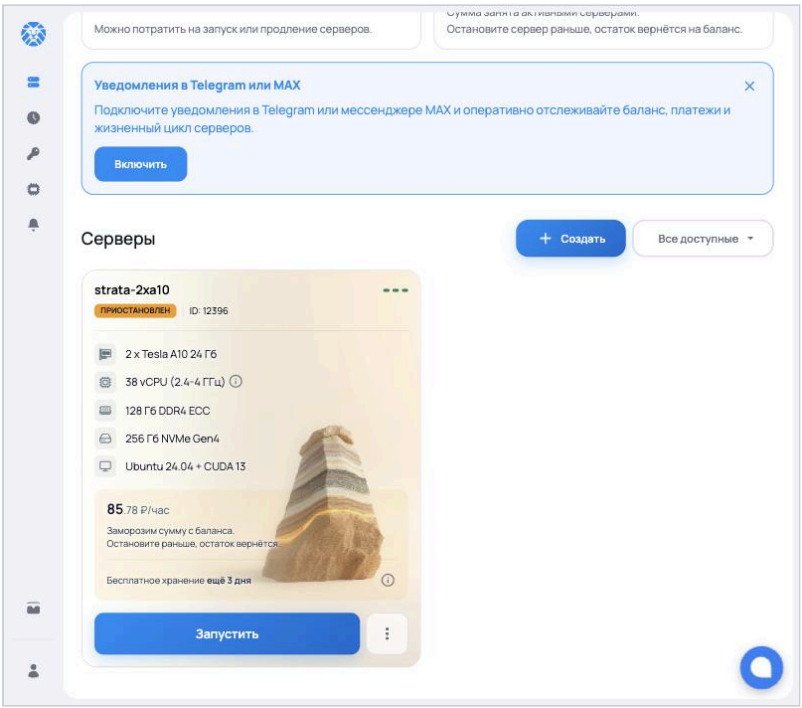


Рисунок 23. Приостановленный сервер: кнопка «Запустить» и срок бесплатного хранения

Стоимость хранения определяется только объёмом диска. Первые трое суток после остановки хранение бесплатно. Затем, по сведениям панели, закреплённое за сервером оборудование освобождается, а за хранение диска списывается 5 ₽ за 1 ГБ в месяц. Значения для расчёта приведены в таблице 10.

Таблица 10. Стоимость работы и хранения сервера с двумя A10

Состояние сервера	Диск 128 ГБ	Диск 256 ГБ
Работает (в час)	83,88 ₽	85,78 ₽
Работает (в сутки)	около 2 013 ₽	около 2 059 ₽
Работает (месяц без перерыва)	около 60 400 ₽	около 61 800 ₽
Приостановлен, первые 3 суток	бесплатно	бесплатно
Приостановлен, после 3 суток (в час)	около 0,89 ₽	1,78 ₽ (по данным карточки)
Приостановлен, после 3 суток (в месяц)	около 640 ₽	около 1 280 ₽
Удалён	0 ₽	0 ₽

Из таблицы 10 следует практическое правило. Сервер, который используется несколько часов в день, выгоднее каждый раз выключать: восемь рабочих часов в день обходятся примерно в 690 ₽, а круглосуточная работа в 2 059 ₽. Сервер, который понадобится через неделю-две, выгоднее оставить приостановленным: хранение дешевле повторной установки и бережёт время. Сервер, который больше не нужен, следует удалить через меню «⋮» в карточке. Следует учитывать, что после освобождения оборудования повторный запуск возможен только при наличии свободных видеокарт нужной модели (раздел 4.5).

> **Напоминание.** Остановку можно выполнить и командой `shutdown -h now` на сервере, однако кнопка в панели надёжнее: она гарантированно прекращает почасовые списания и показывает итог. Пока сервер включён, автопродление списывает очередной час с баланса без предупреждения.

12. Типовые затруднения и способы их устранения

Таблица 9. Типовые затруднения

Признак	Причина и порядок устранения
В конфигураторе нужный вариант недоступен (серый индикатор)	Свободных машин нет. Выберите другой вариант по таблице 3 или повторите попытку позднее.
Не удаётся ввести размер диска	Поле изменяется только кнопками «−» и «+»; каждое нажатие «+» удваивает объём.
Вход по ключу SSH отклоняется сразу после запуска	Ключ записывается на сервер в течение одной-двух минут после появления статуса «Работает». Подождите и повторите попытку.
В веб-терминале не вставляется пароль или команда	Консоль VNC не поддерживает вставку. Наберите текст вручную либо подключитесь через ssh (раздел 7.2).
В веб-терминале не вводится «да»	Консоль работает только в английской раскладке. Ответьте `y` или нажмите Enter.
«Не удалось войти … по паролю»	Пароль введён с ошибкой. Скопируйте его заново из окна подключения. После 15 неудачных попыток за 10 минут адрес блокируется на час.
Сценарий завершился с ошибкой, а установка уже шла	Посмотрите журнал командой `tail -n 100 /root/strata-kit/install.log`. Повторный запуск `bash strata_deploy/deploy.sh` безопасен: окружение, движок, модель и ключ используются повторно.
Нажато Ctrl+C во время показа журнала	Прерван только показ, установка продолжается. Следить за ней можно командой `tail -f /root/strata-kit/install.log`.
Запрос к API возвращает 401	Не передан или неверно указан ключ. Проверьте заголовок `Authorization: Bearer КЛЮЧ`.
Запрос к API отклоняется из-за имени модели	В поле `model` указано неверное имя. Используйте имя из таблицы 2.
Сервер внезапно остановился	Закончились средства на балансе или было отключено автопродление. Пополните баланс и запустите сервер; служба `strata` запустится автоматически.
Поле `content` в ответе пустое	Модель израсходовала лимит `max_tokens` на рассуждение (поле `reasoning_content`). Увеличьте лимит или отключите рассуждения параметром `enable_thinking` (раздел 9.1).
Ответ на простой вопрос идёт 10-20 секунд	Включены рассуждения. Для простых задач отключите их (раздел 9.1).

В журнале установки сообщение `no ready-made engine ... HTTP Error 404`	Ожидаемое сообщение: готового движка для этой версии нет, и он компилируется на сервере. Действий не требуется.
При сборке выводится множество предупреждений `warning #128-D`	Предупреждения компилятора CUDA не являются ошибками. Признак успешной сборки: строка `[ok] engine compiled`.
Индикатор загрузки печатается множеством строк	Окно терминала уже, чем строка индикатора, и каждое обновление переносится на новую строку. На установку это не влияет; при желании расширьте окно.

13. Требования безопасности

Пароль root и ключ API являются секретными сведениями. Их не следует пересылать в мессенджерах, публиковать в общих документах и записывать в исходный код программ; ключ API рекомендуется хранить в переменных окружения или в хранилище секретов. Если пароль root мог стать известен посторонним, его следует сменить командой `passwd` на сервере.

Порт API 18080 открыт для подключения из интернета, а доступ к модели защищён только ключом. Межсетевой экран на сервере Intelion по умолчанию выключен. Если сервер нужен только определённым сотрудникам, рекомендуется ограничить доступ к порту их адресами средствами межсетевого экрана `ufw`. При этом порт 22 необходимо оставить открытым, иначе подключение к серверу будет потеряно.

Если ключ API скомпрометирован, удалите файл `/root/strata-api.key` и повторно запустите `bash strata_deploy/deploy.sh`: сценарий создаст новый ключ, а модель и движок будут использованы повторно.

Приложение А. Сводка параметров развёртывания

Таблица А.1. Параметры сервера и развёртывания, на которых проверена инструкция

Поставщик	Intelion Cloud (ООО «Интелион Облако»), личный кабинет intelion.cloud/user_panel
Конфигурация	2x NVIDIA Tesla A10 24 ГБ, 38 vCPU (Intel Xeon Gold 6240R), 128 ГБ DDR4 ECC (125 ГиБ доступно), сетевой диск NVMe 256 ГБ
Образ	Ubuntu 24.04.4 LTS, драйвер NVIDIA 610.57.04, CUDA 13.3 (в конфигураторе указан драйвер 610.43.02)
Стоимость	85,78 ₽ в час с НДС 22 %, предоплата 1 час, автопродление включено
Сетевые настройки	Публичный IPv4-адрес на интерфейсе сервера, межсетевой экран выключен, вход root по паролю разрешён, fail2ban: 15 попыток за 10 минут, блокировка на 1 час
Комплект	strata_deploy v1.0.0 (github.com/pro-deploy/strata_deploy); проверка выполнена на коммите 482b6179d816, из которого собрана v1.0.0 (отличается только выводом номера версии и документацией)
Модель	Qwen3.6-35B-A3B UD-Q4_K_XL, контекст 65 536 токенов, 2 реплики по 4 одновременных запроса
API	http://185.182.108.28:18080/v1, имя модели qwen3.6-35b-a3b, ключ в /root/strata-api.key
Длительность	Создание и запуск сервера около 3 минут; установка Strata около 7 минут; загрузка модели 42 секунды
Расходы на проверку	Сервер работал 42 минуты 34 секунды (10:54-11:38 по Москве); списано 60,86 ₽, остаток предоплаты 24,92 ₽ возвращён на баланс
Быстродействие	54 токена/с на один запрос; 215 токенов/с суммарно при 8 одновременных запросах
Дата проверки	28 октября 2026 года